

Examen de práctica: Arquitectura y SO

CU

Nombre

Dura **40 minutos**. Sin apuntes, formularios ni dispositivos electrónicos: sólo estas hojas, pluma o lápiz y goma. Contesta en el espacio debajo de cada pregunta.

Miden lo mismo que el parcial 1 con casos nuevos.

Varias preguntas piden una cuenta. Hazla en papel: son órdenes de magnitud, y lo que importa es el razonamiento.

Parte 1 · Memoria

1 · Ordena por velocidad

Ordena del más rápido al más lento: SSD, caché L2, registro, RAM, red, caché L1, caché L3. ¿Qué pasa con la capacidad en ese mismo orden?

2 · No cupo

Tu laptop tiene 16 GB de RAM. Procesar una tabla de 2 GB tarda 10 segundos. Una tabla de 40 GB, con el mismo procesamiento, tarda mucho más que 20 veces eso. ¿Por qué no escala en proporción?

3 · En orden o al azar

Dos programas leen los mismos 1,000 millones de números de un arreglo en RAM. Uno los recorre **en orden** y el otro **saltando al azar**. Leen la misma cantidad de datos. ¿Cuál termina antes, y por qué?

Parte 2 · CPU, GPU y FLOPS

4 · ¿CPU o GPU?

Para cada tarea, elige CPU o GPU y di por qué en una frase:

- a) Compilar un programa.
- b) Multiplicar dos matrices de $10,000 \times 10,000$.
- c) Un servidor web que atiende solicitudes pequeñas, cada una con su lógica.
- d) Aplicar el mismo filtro a un millón de imágenes.
- e) Leer un JSON con estructura irregular y validar cada campo.

5 · ¿Cuánto tarda el entrenamiento?

Entrenar un modelo requiere **6×10^{18} FLOP**. Tu GPU anuncia **300 TFLOPS**, pero en la práctica tu código aprovecha sólo el **40 %**. ¿Cuánto tarda, en horas?

6 · El techo de la memoria

Un chip hace **2 TFLOPS** y su memoria entrega **100 GB/s**. Calculas $C[i] = A[i] + B[i]$ con números FP32, de 4 bytes. Por cada suma lees A y B y escribes C.

- a) ¿Cuántos FLOP haces por byte movido?
- b) ¿Cuántos GFLOPS logras como máximo?
- c) ¿Ayuda cambiar a un chip con el doble de FLOPS y la misma memoria?

7 · ¿Vale la pena la copia?

Tienes 1 GB de datos en RAM. La GPU los procesa en 5 ms, y la CPU en 200 ms. Copiar a la GPU viaja a unos 25 GB/s, y el resultado de vuelta es pequeño.

- a) ¿Quién termina antes?
- b) ¿Y si la CPU tardara 30 ms?

8 · GHz contra trabajo

El chip X corre a **5 GHz** y termina en promedio **2 instrucciones por ciclo**. El chip Y corre a **3.5 GHz** y termina **4 instrucciones por ciclo**. Para un programa de un solo hilo que no espera a la memoria, ¿cuál es más rápido?

Parte 3 · ISA y sistema operativo

9 · El binario que no corre

Compilas un programa en C en tu laptop x86-64 y copias el ejecutable a una Raspberry Pi, que es ARM. ¿Corre? ¿Y un script de Python copiado igual?

10 · ¿Quién habla con el disco?

En Python escribes `open("datos/ventas.csv").read()`. ¿Tu programa le habla al disco directamente? Nombra dos cosas que hace el sistema operativo en ese momento.

11 · ¿Dónde está el cuello de botella?

Un ETL nocturno lee **2 TB** de CSV desde un SSD que entrega unos **2 GB/s**, filtra filas con una condición simple y escribe un resultado pequeño. Alguien propone comprar una GPU para acelerarlo. ¿Ayudaría?
